

Nepristrasna detekcija melanoma

Katarina Krstin, Jovan Vučković

Softversko Inženjerstvo i Informacione Tehnologije, Univerzitet u Novom Sadu, Fakultet tehničkih nauka
krstin.sv57.2021@uns.ac.rs, vuckovic.sv64.2021@uns.ac.rs

I. PROBLEM

Melanom, maligna kožna lezija, je jedan od najagresivnijih oblika raka kože. Njegovo rano otkrivanje je ključno za poboljšanje lečenja kod pacijenata [1]. Standardni dijagnostički postupak je dermatoskopija, koja omogućava detaljniji uvid u strukture kožnih lezija [2]. Ona se služi dermatoskopom koji pravi slike lezija visokog kvaliteta za dalju analizu. Rast broja pacijenata i složenost vizuelne procene ukazuju na potrebu za efikasnijim dijagnostičkim pristupima [1].

Dijagnoza melanoma u kliničkoj praksi se zasniva na ABCDE kriterijumima – asimetrija (engl. *asymmetry*), ivice (engl. *borders*), boja (engl. *color*), prečnik (engl. *diameter*) i evolucija, promene tokom vremena (engl. *evolution*). Njihova primena zahteva vreme i iskustvo dermatologa [3]. Automatizovani sistemi zasnovani na veštačkoj inteligenciji efikasno analiziraju velike skupove dermoskopskih slika [1]. Automatski primenjuju dijagnostičke smernice i izdvajaju podatke od kliničkog značaja [2]. Time se smanjuje broj propuštenih slučajeva, dermatolozi se rasterećuju i omogućuje se fokus na složenije dijagnostičke izazove.

Ovakvi sistemi su predmet brojnih istraživanja, ali ostaje pitanje njihove nepristrasnosti – da li podjednako pouzdano prepoznaju melanome kod pacijenata sa različitim tonovima kože. Nepristrasni modeli doprineli bi ravnopravnijem pristupu zdravstvenoj zaštiti i smanjenju rizika od pogrešne dijagnoze kod ranjivih grupa pacijenata. Nedostatak uravnoteženih skupova podataka, u kojima su zastupljeni svi tonovi kože, otežava izgradnju modela koji imaju jednaku tačnost za sve grupe [1]. Potrebno je razvijati tehnike koje unapređuju nepristrasnost, kako bi modeli zadržali visoke performanse bez favorizovanja određenih populacija.

II. TEORIJSKE OSNOVE

Opisani problem rešavamo primenom metoda dubokog učenja. Akcenat se stavlja na nepristrasnost modela. Nepristrasnost u veštačkoj inteligenciji (engl. *fairness in AI*) odnosi se na razvoj algoritama koji ostvaruju ujednačene performanse u različitim demografskim i fiziološkim grupama [4]. U slučaju detekcije melanoma, pristrasni modeli mogu da imaju višu tačnost za pacijente sa svetlijim tonovima kože, dok kod tamnijih tonova ostvaruju značajno slabije rezultate [5]. Takva razlika direktno utiče na pouzdanost i kvalitet dijagnostičkog procesa, što može rezultovati neujednačenim kliničkim ishodima među pacijentima različitih tonova kože.

Dijagnostika melanoma odvija se u različitim uslovima. Klinički faktori potiču od osobina pacijenata i lezija. Ton kože i varijacije u boji lezija direktno utiču na pouzdanost dijagnostike [5]. Neravnomerna distribucija boje lezija povećava rizik od pogrešne klasifikacije. Tehnički faktori potiču od načina prikupljanja i obrade podataka, oni uključuju neravnotežu u dostupnim dataset-ovima, pri čemu većina sadrži slike osoba svetlige kože [1]. Takva pojava uzrokuje pristrasnost modela. Razumevanje ovih faktora

pokazuje da problem nije samo u algoritmu. Ono ukazuje da poboljšanja moraju da uključe i kliničku praksu i izgradnju uravnoteženih skupova podataka.

Cilj mašinskog učenja kod ovog problema je razviti model koji precizno detektuje maligne lezije i postiže jednaku tačnost za sve tonove kože [5]. Tonovi kože sa slika u *dataset-u* su prethodno označeni prema *Monk Skin Tone* (MST) skali. Ona je standardna desetostruka skala razvijena od strane *Google-a*. Kvantificuje nijanse kože od svetlih do tamnih. To omogućava evaluaciju i treniranje modela sa ciljem postizanja jednako preciznih predikcija za sve grupe tonova kože [1]. Performanse modela ocenjuju se metrikama kao što su tačnost (engl. *accuracy*), AUC-ROC (engl. *Area Under the Receiver Operating Characteristic Curve*), odaziv (engl. *recall*) i F-mera (engl. *F1-score*), koje pokazuju koliko dobro model razlikuje maligne i benigni slučajeve [2]. Nepristrasnost modela meri se standardnom devijacijom predikcija po grupama tonova kože (engl. *Fairness parity*) i *Fairlearn* metrike, kao što je *demographic parity difference*, da bi se proverilo da li model favorizuje neku grupu [4].

$$\text{Fairness parity} = \sigma(\mu_1, \mu_2, \dots, \mu_G)$$

G - broj grupa po tonovima kože (10 po MST skali)

μ_G - prosečna predikcija modela za grupu G


Model mora biti otporan na šum, koji nastaje zbog promena osvetljenja, rezolucije slika ili prisustva artefakata na slici. Interpretabilnost je važna za razumevanje odluka modela i poverenje dermatologa.

Korišćen je CNN model zasnovan na *EfficientNetB0* arhitekturi. *EfficientNet* je *state-of-the-art* arhitektura koja postiže visoku tačnost uz manji broj parametara i brže treniranje u poređenju sa klasičnim modelima, poput *ResNet-a* i *VGG-a* [2]. Arhitektura koristi uniformno skaliranje (engl. *compound scaling*), što omogućava istovremeno povećanje širine, dubine i rezolucije modela, omogućavajući detaljniju analizu lezija bez gubitka brzine obrade. Za poboljšanje generalizacije korišćen je transfer znanja sa modela treniranog na *ImageNet* skupu. *FairSkinToneLoss* dodatno je uveden kako bi se model trenirao da predviđa jednako precizno za sve MST grupe tonova kože [5]. *FairSkinToneLoss* funkcija je modifikovana funkcija gubitka koja kažnjava model za razlike u predikcijama po MST grupama. Ovaj pristup omogućava da model zadovolji zahteve kliničke preciznosti, nepristrasnosti i robusnosti na varijacije u kvalitetu i osvetljenju slika [5].

III. REŠENJE

Cilj rada je razvoj modela za nepristrasnu detekciju melanoma nezavisno od tona kože. Kao ulaz očekuju se fotografije kožnih lezija uz opcione metapodatke o pacijentu. Izlaz sistema je binarna klasifikacija — benigno ili maligno — uz obezbeđivanje uravnoteženih performansi po svim grupama tonova kože. Na ovaj način, model smanjuje pristrasnost, što ga čini primenjivim u kliničkim i

istraživačkim okruženjima gde je inkluzivnost od ključne važnosti.



Slika 1: Struktura Rešenja

Slika 1 ilustruje korake u rešavanju problema detekcije melanoma.

A. Preprocesiranje

Za izradu rada korišćen je skup podataka *ISIC Challenge 2020* podeljen u skup za trening i skup za test. Podaci su nebalansirani, samo 1,7% podataka je maligno, takođe ima malo slika sa najtamnjim tipom kože. U fazi preprocesiranja, metapodaci sa string vrednostima su kodirani metodom one-hot enkodiranja kako bi se izbeglo uvođenje veštačkog ordinalnog odnosa između kategorija. Sve slike su učitane u RGB formatu i uniformno skalirane na 244×244 piksela radi standardizacije ulaza [6]. Kako bi se obezbedila robusnost modela i smanjilo overfitovanje, primenjena je augmentacija pomoću biblioteke *Albumentations*, uključujući rotacije, translacije, promene kontrasta i osvetljenja, zamućenja i geometrijske transformacije. Svaka maligna slika augmentovana je više puta kako bi se postigla bolja balansiranost skupa [7]. Tonovi kože su labelirani pomoću *MST* skale. Ton kože sa slike se određivao na osnovu skale i *Delta E 2000* algoritma. Boja sa slike uzeta je pomoću super-piksela. Izdvojena je regija kože, boja je uprosećena srednjom vrednošću tona kože i prosledena algoritmu *Delta E 2000* za označavanje konkretnе labele [8].

B. Treniranje modela

Za treniranje modela korišćen je *EfficientNet* kao osnovna arhitektura [9]. Upotrebljen je unapred trenirani model na *ImageNet* skupu, pri čemu je uklonjen klasifikacioni sloj i zamenjen globalnim prosečnim *pooling-om* [10]. Na taj način dobijene su kompaktne reprezentacije slika. One su integrisane sa meta-podacima. Meta-podaci se obrađuju kroz mrežu sa dva potpuno povezana sloja, *Swish* aktivacijom i *batch* normalizacijom [4]. Izlazi iz obe grane – slike i meta-podataka – spajaju se i šalju u završni sloj za binarnu klasifikaciju [10].

Korišćena je prilagođena implementacija *Swish* funkcije sa ručno definisanim gradijentom, kako bi se poboljšao protok gradijenata i stabilnost učenja [12]. Tokom treniranja, model je koristio pet *dropout* slojeva sa 50% verovatnoće isključivanja neurona [14]. Za svaku propagaciju izlaz se računa kroz sve *dropout* slojeve i proseči, čime se dobija konačna predikcija [15]. Meta-podaci, ako su prisutni, prolaze kroz zasebnu mrežu sa *dropout* slojem od 30% između *dense* slojeva [6].

Funkcija gubitka, *FairSkinToneLoss*, zasniva se na binarnoj unakrsnoj entropiji (*BCE*), proširenoj kaznenim faktorom za neuravnovežene predikcije po grupama tonova kože [11]. Ona se definiše kao:

$$\begin{aligned} Loss = & -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \\ & + \alpha \cdot \sigma_{MST}(\hat{y}) \end{aligned}$$

Gde je:

$y_i \in \{0, 1\}$ - stvarna labela (benigno/maligno)

\hat{y}_i - predikcija modela

N - broj primera u *batch-u*

$\sigma_{MST}(\hat{y})$ - standardna devijacija prosečnih predikcija po

MST grupama tonova kože

α - težina *fairness* kazne

Ovaj faktor kazne podstiče model da smanji razlike u predikcijama između tonova kože, što doprinosi uravnoveženijoj klasifikaciji melanoma i povećava pouzdanost modela za sve tipove kože [4].

IV. REZULTATI

Cilj evaluacije bio je da se ispita da li predloženi model može da postigne visoku tačnost u detekciji melanoma i da istovremeno obezbedi ravnomerne performanse za sve grupe tonova kože prema *MST* skali. Poželjni ishodi evaluacije bili su $AUC \geq 0.85$ i minimalne razlike u performansama između grupa manja od 5%. Neželjeni ishodi su niski odziv (engl. *recall*) za maligne slučajeve ili izražene razlike u performansama između svetlijih i tamnijih tonova kože.

Da bismo utvrdili da li je naše rešenje primenljivo u praksi, model je evaluiran nad unapred podeljenim *ISIC 2020* skupom podataka, koji sadrži odvojene skupove za treniranje i testiranje. Procedura evaluacije obuhvatila je primenu modela na test skupu, uz izračunavanje standardnih metrika performansi: tačnost, odziv (engl. *recall*), F1 mera i *AUC-ROC*. Pored toga, evaluirane su i mere nepristrasnosti korišćenjem *Fairlearn* biblioteke – standardna devijacija predikcija po grupama tonova kože i *demographic parity difference*, pri čemu su kožni tonovi klasifikovani pomoću *Delta E 2000* algoritma i mapirani na *MST* skalu (10 grupa).

Model je postigao ukupnu tačnost od 85,9%, sa *AUC-ROC* od 0,83 i F1 merom od 0,78. Recall za maligne slučajeve iznosio je 0,74, što pokazuje da model prepoznaje pozitivne slučajeve, ali sa značajnim prostorom za poboljšanje. Rezultati po grupama tonova kože prikazani su u Tabeli I.

Tabela I: Rezultati

MST grupa	Accuracy	Recall	F1	AUC
1-2 (svetla)	87,5%	0,76	0,79	0,84
3-5 (srednja)	85,8%	0,73	0,77	0,82
6-8 (tamna)	84,1%	0,71	0,74	0,80
9-10 (vrlo tamna)	83,5%	0,68	0,72	0,79

Standardna devijacija tačnosti između grupa bila je 1,7%, dok je *demographic parity difference* iznosio 0,11, što ukazuje na vidljive razlike u performansama između grupa, naročito kod tamnijih tonova kože.

Niske performanse modela delom se mogu pripisati neravnomerenoj zastupljenosti tonova kože u *ISIC 2020* skupu podataka. Iako je augmentacija primenjena na maligne slučajeve radi balansiranja klasa, tamniji tonovi kože su i dalje slabije zastupljeni, što se odražava u nižoj tačnosti i recall vrednostima za *MST* grupe 6–10. Ručnim pregledom predikcija uočavamo da model ponekad ne

prepoznaće maligne lezije na tamnijim tonovima kože, dok kod svetlijih i srednjih tonova preciznost ostaje znatno viša.

FairSkinToneLoss je uveden da bi se smanjila pristrasnost između grupa, vrednosti standardne devijacije i *demographic parity difference* pokazuju da blage razlike i dalje postoje, naročito kod najtamnijih tonova kože. Ove razlike ukazuju na to da model nije u potpunosti uspeo da generalizuje i da je potrebna dodatna optimizacija i veća zastupljenost svih *MST* grupa u trening skupu.

Uprkos ovim ograničenjima, model pokazuje solidne performanse za svetlijе i srednje tonove kože, što ga čini pouzdanim u kontekstu ranog prepoznavanja melanoma u tim grupama. Međutim, za kliničku primenu kod tamnijih tonova kože potrebne su dodatne strategije, kao što su prošireni skupovi podataka, naprednije tehnike augmentacije i dodatna fina podešavanja modela.

LITERATURA

- [1] Laura N Montoya, Jennafer Shae Roberts, and Bel'en S'anchez Hidalgo: *Towards Fairness in AI for Melanoma Detection: Systematic Review and Recommendations*
- [2] Rotemberg, V., Kurtansky, N., Betz-Stablein, B., Caffery, L., Chousakos, E., Codella, N., Combalia, M., Dusza, S., Guitera, P., Gutman, D., Halpern, A., Helba, B., Kittler, H., Kose, K., Langer, S., Lioprys, K., Malvehy, J., Musthaq, S., Nanda, J., Reiter, O., Shih, G., Stratigos, A., Tschandl, P., Weber, J., & Soyer, H. P. (2021). *A patient-centric dataset of images and metadata for identifying melanomas using clinical context*. *Scientific Data*, 8, 34.
- [3] N. R. Abbasi, H. M. Shaw, D. S. Rigel, R. J. Friedman, W. H. McCarthy, I. Osman, A. W. Kopf, and D. Polsky, "Early diagnosis of cutaneous melanoma: Revisiting the ABCD criteria," vol. 292, no. 22, pp. 2771– 2776.
- [4] NINAREH MEHRABI, FRED MORSTATTER, NRIPSUTA SAXENA, KRISTINA LERMAN, and ARAM GALSTYAN, USC-ISI: *A Survey on Bias and Fairness in Machine Learning*
- [5] *Disparities in Dermatology AI Performance on a Diverse, Curated Clinical Image Set*
- [6] Nils Gessert, Maximilian Nielsen, Mohsin Shaikh, René Werner, Alexander Schlaefer *Skin Lesion Classification Using Ensembles of Multi-Resolution EfficientNets with Meta Data*
- [7] Suorong Yang, Weikang Xiao, Mengchen Zhang, Suhan Guo, Jian Zhao, Furao Shen, 2022. *Image Data Augmentation for Deep Learning: A Survey*
- [8] Suorong Yang, Weikang Xiao, Mengchen Zhang, Suhan Guo, Jian Zhao, Furao Shen *Automatic skin lesion segmentation on dermoscopic images by the means of superpixel merging*
- [9] Tan, M. & Le, Q. V., "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019.
- [10] Deng, J. et al., "ImageNet: A Large-Scale Hierarchical Image Database," *CVPR*, 2009.
- [11] Chollet, F., *Deep Learning with Python*, 2nd Edition, Manning Publications, 2021.
- [12] Ramachandran, P., Zoph, B., Le, Q.V., "Searching for Activation Functions," *arXiv preprint arXiv:1710.05941*, 2017.
- [13] Ioffe, S. & Szegedy, C., "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," *ICML*, 2015.
- [14] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. *Journal of Machine Learning Research*, 15, 1929-1958.
- [15] Gal, Y., & Ghahramani, Z. (2016). *Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning*. In ICML.